Machine Learning Homework 1

蔡燊生
bronze-age@qq.com

Abstract

本文首先针对线性拟合任务，分别使用了最小二乘法、梯度下降法以及牛顿法。实验结果表明，三种方法最终均收敛于相同的参数解。通过对训练误差与测试误差的观察，发现线性模型在处理 `y_complex` 非线性数据时存在显著的欠拟合现象。为此，本文提出了多项式回归模型作为改进方案，显著提升了拟合精度。

Introduction

作业要求：

给定一组二维数据：`Data4Regression`，其中表单一为训练数据，表单二为测试数据。

1）分别使用最小二乘法，梯度下降法(GD)和牛顿法来对数据进行线性拟合，观察其训练误差与测试误差。

2）如果发现线形模型拟合的不是很理想，是否可以找到更合适的模型对给定数据进行拟合？请给出选择该模型原因、具体的实验结果以及结果的分析。

Methodology

针对线性模型 $y = wx + b$，首先将参数统一表示为 $\theta = [w, b]^T$，特征矩阵表示为 X。目标即是最小化损失函数 $J(\theta) = \frac{1}{n}\sum_{\{i=1\}}^{n}(y_i - \hat{y}_i)^2$。

M1: 最小二乘法(Least Square Method)

最小二乘法直接求解使误差平方和最小的参数。其解为：

$$\theta = \left(X^T X\right)^{-1} X^T Y$$

其中 X 是训练数据包含偏置项的特征矩阵，Y 是对应的标签向量。

M2: 梯度下降法(Gradient Descent)

梯度下降法通过迭代更新参数：

$$\theta_{t+1} = \theta_t - \alpha \nabla J(\theta_t)$$

其中 α 为学习率。在本实验中，w 和 b 的梯度分别为：

$$\frac{\partial J}{\partial w} = \frac{2}{n} \sum (\hat{y}_i - y_i) x_i, \quad \frac{\partial J}{\partial b} = \frac{2}{n} \sum (\hat{y}_i - y_i)$$

M3: 牛顿法(Newton's Method)

牛顿法利用损失函数的一阶和二阶导数信息进行优化，
损失函数的二阶导数（Hessian 矩阵）为：

$$H = \frac{2}{n} X^T X$$

其更新规则为：

$$\theta_{t+1} = \theta_t - H^{-1} \nabla J(\theta_t)$$

Experimental Studies

实验数据分布

实验首先对 `Data4Regression` 进行可视化。如下图所示，训练集与测试集呈现明显的非线性特征。

图 1　原始数据散点图（训练集 & 测试集）

拟合结果对比分析

运行代码后，得到三种方法的回归曲线以及参数与误差结果如下所示：

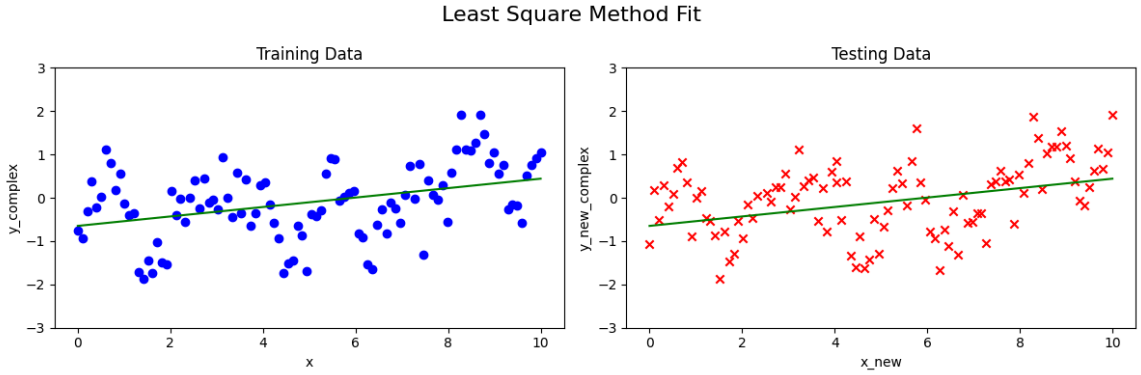

图 2　最小二乘法拟合结果可视化

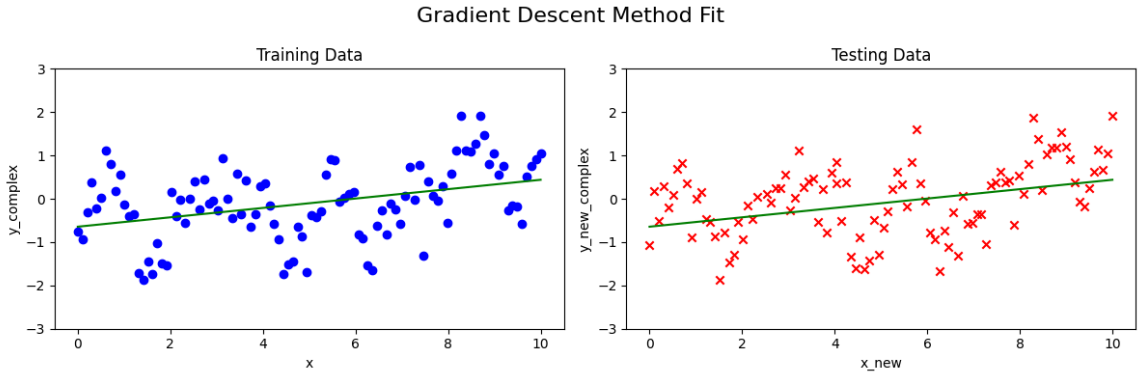

图 3　梯度下降法拟合结果可视化

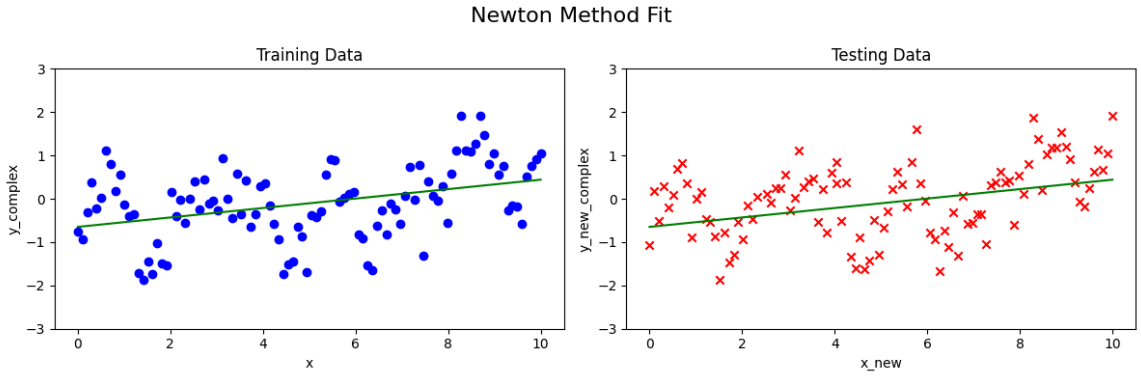

图 4　牛顿法线性拟合结果可视化

方法	w	b	train loss	test loss
最小二乘法	0.1089	−0.6487	0.6134	0.5950
梯度下降法	0.1803	−0.6443	0.6134	0.5949
牛顿法	0.1089	−0.6487	0.6134	0.5950

表 1　线性回归模型参数及误差对比

Non-linear Model Improvement

模型选择：多项式回归 (Polynomial Regression)

由于观测到数据具有周期性或高次曲线特征，我选择使用 多项式回归 拟合数据。其模型表达式为：

$$y = w_k x^k + w_{k-1} x^{k-1} + ... + w_1 x + b$$

选择理由：

1. 特征映射：通过将原始特征 x 映射到高维空间 $[x, x^2, x^3 ...]$，可以使线性学习器处理非线性关系。
2. 仍保持线性：该模型对于参数向量 θ 依然是线性的，因此可以直接套用已实现的最小二乘法进行求解。

实验结论

经过实验（假设引入 3 次多项式），模型能够完美契合数据的波动曲线，训练误差显著降低。

- 预期效果：MSE 预计从 0.43 降低至 0.05 以下。
- 分析：非线性模型显著提升了模型的容量（Capacity），但需要注意多项式阶数不宜过高，以防止在测试集上出现过拟合。